

Relatório Executivo de Logs IIS

Leitura gerencial de capacidade, lentidão, falhas e oportunidades de ganho para reduzir infraestrutura necessária e acelerar processamento.

Arquivo: u_ex260528_x.log

Período: 2026-05-27 23:59:56 a 2026-05-28 06:26:45 UTC

Fonte: IIS W3C + SOAPAction

REQUISIÇÕES

428.142

6h27 de janela analisada

P95 GLOBAL

4,1s

p99 9,4s

>= 5 SEGUNDOS

14.160

3.840 acima de 10s

WSDL/XSD

179.285

41,9% do volume

Maior ofensor de capacidade: EnviaLaudoAtendimentoLista

Não é o maior volume, mas consome ~1.429 minutos de processamento, com p99 de 30,2s e máximo de 365,6s. É o primeiro alvo para ganho real de infraestrutura.

Erro recorrente de infraestrutura: /worklab health check

Foram 9.036 respostas 404 em
`/worklab/drvRastreabilidadePedido/valida/v1.0/check/true`. Corrigir isso limpa alertas falsos e reduz ruído operacional.

Polling domina o volume

`ConsultaStatusAtendimento` representa 38,8% de todas as chamadas. Um backoff de 30% pouparia ~49,9 mil chamadas e ~411 minutos de processamento no período.

Busca por período tem risco desproporcional


`BuscaResultadosPorPeriodo` tem apenas 570 chamadas, mas p95 de 38s, p99 de 100s e máximo de 203,6s. Precisa de paginação, limite de janela e análise de índice.

Volume por função

ConsultaStatusAtendimento




BuscaPendenciasMPP



EnviaLaudoAtendimentoLista



EnviaLaudoAtendimento



EnviaLoteResultados




EnviaResultadoBase64



EnviaLoteResultadosV3




RecebeAtendimento



Lentidão por p95

BuscaResultadosPorPeriodoV3



Volume e latência por função SOAP

FUNÇÃO	VOLUME	% TOTAL	AVG	P95	P99	MÁX	>=5S
ConsultaStatusAtendimento	166.167	38,8%	495ms	2,5s	6,1s	24,8s	2.667
BuscaPendenciasMPP	42.820	10%	651ms	3,4s	6,3s	21,2s	804
EnviaLaudoAtendimentoLista	38.550	9%	2,2s	8s	30,2s	365,6s	3.106
EnviaLaudoAtendimento	33.435	7,8%	1,6s	6,2s	15,2s	91,1s	2.361
EnviaLoteResultados	32.344	7,6%	960ms	4,3s	9s	67,3s	1.198
EnviaResultadoBase64	19.325	4,5%	941ms	4,4s	8,2s	32,6s	765
EnviaLoteResultadosV3	15.824	3,7%	613ms	3,2s	6,2s	42,2s	284
RecebeAtendimento	11.904	2,8%	2,3s	6,7s	10,8s	23,4s	1.167
EnviaLaudoAtendimentoV3	9.654	2,3%	1,7s	6,6s	16,8s	79,6s	768
EnviaLaudoAtendimentoListaV3	5.158	1,2%	1,9s	6,6s	18,1s	88,6s	432

FUNÇÃO	VOLUME	% TOTAL	AVG	P95	P99	MÁX	>=5S
BuscaResultadosPorPeriodo	570	0,1%	8,5s	38s	100s	203,6s	184
BuscaProcedimentos	307	0,1%	8,6s	32,2s	47,6s	61,7s	114

Maiores consumidores de capacidade

FUNÇÃO	TEMPO ACUMULADO	PESO VISUAL	EVENTOS >=5S	DIAGNÓSTICO
ConsultaStatusAtendimento	1.370 min		2.667	Volumoso
BuscaPendenciasMPP	465 min		804	Volumoso
EnviaLaudoAtendimentoLista	1.429 min		3.106	Cauda
EnviaLaudoAtendimento	879 min		2.368	Cauda
EnviaLoteResultados	517 min		1.198	Volumoso
EnviaResultadoBase64	303 min		765	Volumoso
EnviaLoteResultadosV3	162 min		284	Volumoso
RecebeAtendimento	456 min		1.167	Cauda
EnviaLaudoAtendimentoV3	268 min		768	Cauda
EnviaLaudoAtendimentoListaV3	161 min		432	Cauda

Ações de ganho imediato

AÇÃO	GANHO ESPERADO	ESFORÇO	IMPACTO
Corrigir health check `/worklab`	9.036 erros 404 deixam de poluir monitoramento e logs.	Baixo	Imediato
Criar `/health` leve e padronizar probes	Remove `GET /` status 0 e evita bater em rota de negócio.	Baixo	Imediato
Cachear WSDL/XSD nos clientes	Pode cortar até 179.285 chamadas de metadados (41,9% do volume observado).	Médio	Alto
Revisar POST com `?wsdl`	Há 201.650 POSTs com query `wsdl`; provável erro de integração ou cliente SOAP mal configurado.	Médio	Alto

AÇÃO	GANHO ESPERADO	ESFORÇO	IMPACTO
Backoff em <code>`ConsultaStatusAtendimento`</code>	Redução de 30% pouparia ~49,9 mil chamadas e ~411 min de processamento no período.	Médio	Alto
Limite/paginação em <code>`BuscaResultadosPorPeriodo`</code>	Baixo volume, mas p95 38s e p99 100s; reduz risco de travamento e timeout.	Médio	Alto
Instrumentar tamanho do lote/payload	Sem <code>`cs-bytes/sc-bytes`</code> , hoje não há medição real de payload.	Baixo	Médio
Separar envio pesado em fila assíncrona	<code>`EnviaLaudoAtendimentoLista`</code> concentra maior consumo e cauda máxima de 365s.	Alto	Muito alto

Proposta de ganho real

INFRA

Reduzir ruído e erro falso

Corrigir `/worklab`, criar `/health`, ajustar probes e remover status 0 de GET `/`.

TRÁFEGO

Cortar metadados repetidos

Cache WSDL/XSD e revisar clientes com POST `?wsdl`. Potencial de reduzir até 41,9% do volume observado.

APLICAÇÃO

Assincronizar laudos/listas

Fila + protocolo de status para `EnviaLaudoAtendimentoLista`, reduzindo timeouts e p99 extremo.

BANCO

Paginar buscas críticas

Limitar período, paginar e revisar índices para `BuscaResultadosPorPeriodo` e `BuscaProcedimentos`.

Roadmap recomendado

PRAZO	FRENTE	AÇÕES	RESULTADO ESPERADO
0-7 dias	Infra e ruído	Corrigir `/worklab`, `/`, criar health leve, cache headers para WSDL, dashboard de p95/p99 por SOAPAction.	Menos erro falso, menor ruído, diagnóstico mais confiável.
7-30 dias	Eficiência operacional	Backoff em polling, cache WSDL nos clientes, limite de janela para buscas por período, logs de tamanho de lote.	Menos requisições, menos CPU, menor latência percebida.
30-90 dias	Arquitetura	Fila para laudos/listas, paginação real, índices de banco, contratos V3 priorizados, migração de clientes legados.	Redução real de infra necessária e estabilidade em picos.
90+ dias	Produto/API	Webhooks/push para status, SLA por cliente, rate limit inteligente, versionamento e descontinuação de clientes antigos.	Escala com menos servidores e menor custo operacional.

Leitura final

Onde melhora mais rápido: corrigir health checks e WSDL/cache. Isso reduz volume artificial, melhora leitura operacional e pode diminuir carga sem tocar regra de negócio.

Onde melhora de verdade: atacar `EnviaLaudoAtendimentoLista`, `EnviaLaudoAtendimento`, `RecebeAtendimento` e `BuscaResultadosPorPeriodo`. Esses endpoints combinam volume, latência e cauda longa.

Onde faltam dados: tamanho real de payload, quantidade de registros por lote, cliente lógico, correlation-id e tempos internos de banco/serialização. Sem isso, dá para priorizar ofensores, mas ainda não dá para atribuir causa raiz com precisão cirúrgica.

Relatório gerado a partir do JSON estruturado em `outputs/iis-log-analysis.json`. Como o log IIS não possui `cs-bytes/sc-bytes`, volume de dados foi estimado por requisições e tempo de processamento.